Rapport SAE Régression sur données réelles

Groupe : Arthur Renault-Clequin , Margot Marciano, Louis Contat
BUT Science des Données – IUT Rives de seine

SOMMAIRE

1. Introduction..... p. 3

2. Analyse descriptive..... p. 4 à 6
2.1 Statistiques descriptives..... p. 4
2.2 Visualisations..... p. 5 à 6

3. Ajustement des courbes de croissance ..... p. 7 à 10
3.1 Méthodologie de l'ajustement polynomial..... p. 7
3.2 Choix du degré optimal..... p. 8
3.3 Interpretation des courbes ajustées..... p. 9 à 10

4. Courbes de croissance par tranche d'âge..... p. 11 à 13
4.1 Méthode de construction des indicateurs de croissance..... p. 11
4.2 Analyse des graphiques de croissance..... p. 12 à 13

5.Conclusion..... p. 14 à 15
5.1 Bilan général..... p. 14
5.2 Summary..... p. 15

1. Introduction

La croissance des enfants et des adolescents est un indicateur majeur en santé publique. Elle permet de surveiller leur développement physique et de détecter d'éventuels retards ou anomalies. En 2020, une étude internationale menée dans plus de 90 pays a recueilli des données sur la taille et l'âge d'enfants de 5 à 19 ans afin de produire des courbes de croissance adaptées aux réalités actuelles.

Dans chaque pays, des médecins généralistes et des pédiatres ont relevé l'âge et la taille de vingt enfants choisis au hasard. L'âge est exprimé en années décimales et la taille en centimètres, avec une précision allant jusqu'à plusieurs décimales. Cette précision permet de réaliser des analyses statistiques détaillées et des ajustements de courbes plus fins.
Les données exploitées dans ce projet proviennent des pays Palau et Gabon et sont contenues dans le fichier **Data_Projet22.Rdata**. Elles comprennent les 4 variables ci-dessous :

· **Pays :** Palau ou Gabon
· **Sexe :** Boys (garçon) ou Girls (fille)
· **Âge :** exprimé en années décimales
· **Taille :** exprimée en centimètres

Pour chacun des deux pays, l'échantillon se compose de **4000 enfants**, répartis équitablement entre filles et garçons.

Ce travail s'inscrit dans le cadre de la SAE « **Régression sur données réelles** ».
Nous cherchons à étudier l'évolution de la taille en fonction de l'âge, en tenant compte du sexe et du pays. Nous débuterons par une analyse descriptive des données afin de mieux comprendre la distribution des variables. Nous poursuivrons avec l'ajustement de courbes polynomiales, en choisissant le degré optimal grâce au critère AIC (Akaike Information Criterion). Enfin, nous tracerons les courbes médianes ainsi que celles des premiers et troisièmes quartiles afin de visualiser les tendances générales et la dispersion des tailles selon l'âge. Ces analyses permettront de comparer les profils de croissance entre les sexes et les deux pays étudiés.

2. Analyse descriptive

2.1 Statistiques descriptives

a) Variable Âge

Statistiques descriptives : Âge

Pays	Sexe	Moy_Age	Med_Age	Q1_Age	Q3_Age	SD_Age
Gabon	Boys	12.0	12.1	8.38	15.6	4.06
Gabon	Girls	12.1	12.1	8.51	15.6	4.10
Palau	Boys	12.1	12.1	8.46	15.8	4.11
Palau	Girls	12.1	12.2	8.64	15.5	4.07

L'analyse des âges montre des distributions relativement proches entre les différents groupes. L'âge moyen se situe autour de 12 ans pour l'ensemble des sous-groupes (filles et garçons de Palau et du Gabon). La médiane est également très proche de la moyenne, ce qui indique une distribution assez symétrique des âges. Les premiers quartiles (Q1) sont compris entre environ 8,4 et 8,6 ans, tandis que les troisièmes quartiles (Q3) se situent autour de 15,5 à 15,8 ans, ce qui montre une répartition équilibrée des âges sur l'ensemble de l'intervalle prévu par l'étude (5 à 19 ans). L'écart-type, proche de 4 ans dans tous les groupes, confirme une dispersion comparable des âges entre les pays et les sexes.

b) Variable Taille

Statistiques descriptives : Taille

Pays	Sexe	Moy_Taille	Med_Taille	Q1_Taille	Q3_Taille	SD_Taille
Gabon	Boys	144	146	127	156	6.5
Gabon	Girls	143	149	128	156	6.4
Palau	Boys	149	151	131	158	6.7
Palau	Girls	144	150	132	153	6.3

En ce qui concerne la taille, on observe des différences plus marquées entre les groupes. Les garçons de Palau présentent la taille moyenne la plus élevée avec environ 149 cm, contre 144 cm pour les garçons du Gabon. Les filles de Palau et du Gabon ont des tailles moyennes proches (respectivement 144 cm et 143 cm). Les médianes de taille suivent le même ordre. Les premiers quartiles indiquent que 25 % des enfants les plus petits mesurent entre 127 cm et 132 cm selon le groupe. Les données montrent une croissance plus marquée chez les garçons de Palau, tandis que les autres groupes présentent des tailles plus proches. Ces résultats illustrent bien les premières différences de croissance selon le sexe et le pays.

2.2 Visualisations

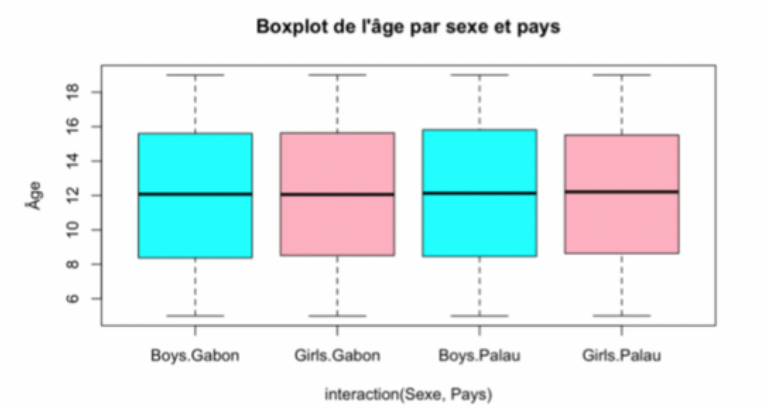

Les boîtes à moustaches représentant la répartition des âges selon le sexe et le pays montrent des distributions relativement proches entre les différents groupes. On observe que la médiane de l'âge est très proche entre tous les groupes, légèrement au-dessus de 12 ans, ce qui confirme les statistiques descriptives précédentes. Les premiers et troisièmes quartiles sont également similaires : le premier quartile se situe autour de 8,4 à 8,6 ans et le troisième entre 15,5 et 15,8 ans. La dispersion apparaît comparable entre les groupes, avec des moustaches de longueur équivalente et l'absence de valeurs extrêmes notables. Ces résultats traduisent une structuration équilibrée des âges selon le sexe et le pays.

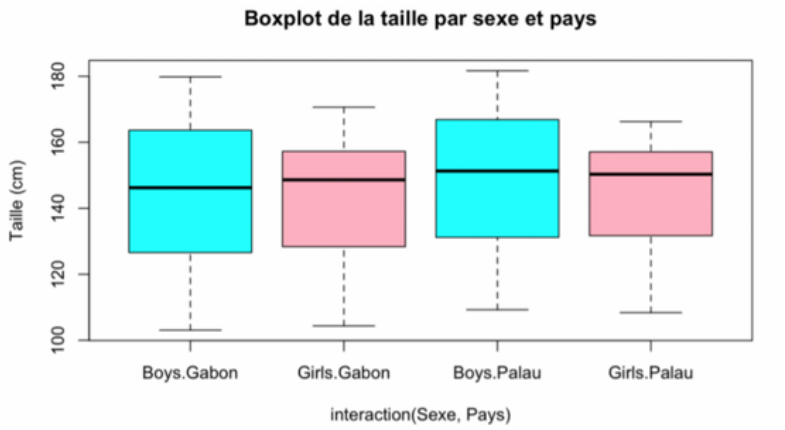

Les boîtes à moustaches illustrant la répartition des tailles révèlent des différences plus marquées. Les garçons de Palau présentent la médiane la plus élevée, autour de 151 cm, ainsi qu'une plus grande dispersion avec des tailles maximales proches de 180 cm. Les garçons du Gabon ont une médiane légèrement plus basse, proche de 146 cm, et une variation également importante mais légèrement plus restreinte. Les filles des deux pays ont des médianes plus proches (environ 149 cm pour le Gabon et 150 cm pour Palau) et des plages de variation plus étroites que celles des garçons. Ces observations traduisent un avantage de taille des garçons de Palau et laissent apparaître des écarts selon le sexe et le pays.

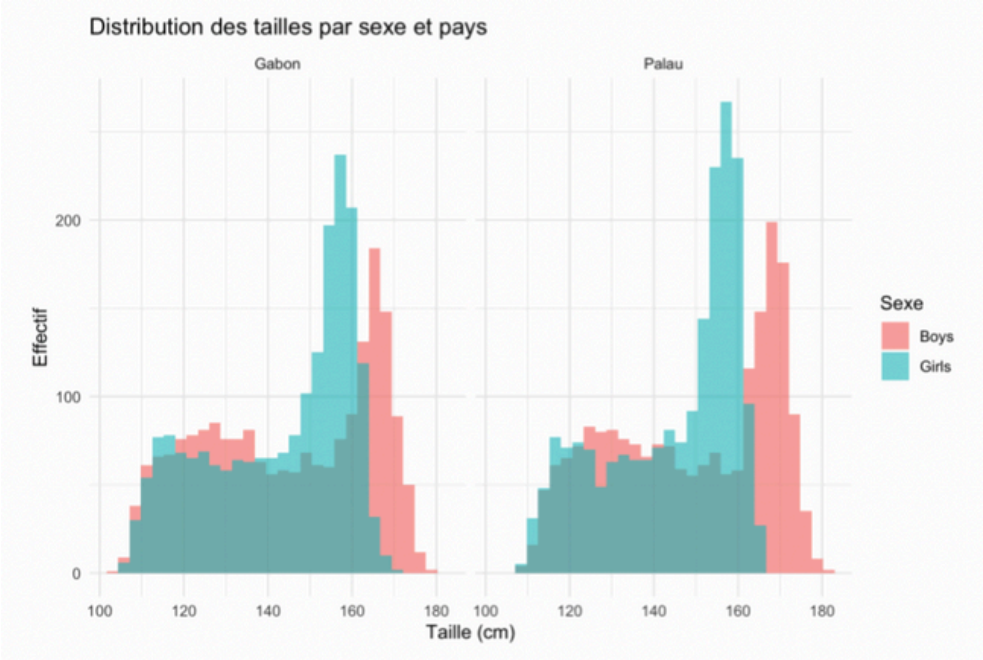

L'histogramme représentant la distribution des tailles par sexe et par pays met en évidence des différences nettes entre les groupes. Les garçons, surtout à Palau, ont tendance à être plus grands, avec un nombre important d'individus dépassant les 170 cm. Les filles des deux pays ont des tailles plus concentrées autour de 150 à 160 cm. Par ailleurs, la forme des distributions reste globalement similaire entre les pays, bien que les garçons de Palau se démarquent par un pic plus marqué dans les classes de grandes tailles.

On constate aussi que les tailles inférieures à 130 cm présentent des effectifs comparables entre les sexes et les pays, ce qui montre que les écarts apparaissent surtout dans les classes supérieures. Cet histogramme complète les boîtes à moustaches en apportant une vue plus précise sur la distribution des tailles et confirme des différences selon le sexe et le pays qui seront explorées lors des ajustements des courbes de croissance.

3. Ajustement des courbes de croissance
3.1 Méthodologie de l'ajustement polynomial

Pour modéliser la relation entre l'âge et la taille des enfants, nous avons choisi d'ajuster des modèles polynomiaux de degré croissant. Cette approche nous permet de représenter la courbe de croissance, qui n'est pas linéaire, de manière plus flexible et fidèle aux données observées. Nous avons réalisé ces ajustements à l'aide de la fonction lm() sous R, en incluant successivement des termes d'ordre supérieur jusqu'au **degré 6**.
Afin d'évaluer la qualité de chaque ajustement, plusieurs indicateurs ont été calculés :

- le **R^2** (coefficient de détermination), qui mesure la proportion de la variance expliquée par le modèle,
- l'**AIC** (Akaike Information Criterion) et le **BIC** (Bayesian Information Criterion), qui permettent de comparer les modèles en tenant compte à la fois de leur ajustement et de leur complexité,
- le **RMSE** (Root Mean Square Error), qui mesure l'erreur moyenne des prédictions

Nous avons appliqué cette méthode de façon identique aux quatre sous-groupes : garçons et filles du Gabon, garçons et filles de Palau. Le tableau ci-dessous illustre nos résultats pour le groupe des garçons du Gabon. On y voit une amélioration progressive des indicateurs lorsque nous augmentons le degré du polynôme : l'AIC et le RMSE diminuent, traduisant un ajustement de plus en plus précis à mesure que la complexité du modèle augmente.

Résultats des ajustements polynomiaux - Garçons Gabon

Degré	R2	AIC	BIC	RMSE
1	0.9556	11429.61	11446.41	4.2079
2	0.9674	10814.10	10836.51	3.6060
3	0.9740	10362.91	10390.91	3.2197
4	0.9749	10293.78	10327.39	3.1630
5	0.9756	10241.44	10280.65	3.1203
6	0.9758	10224.45	10269.26	3.1055

Ce tableau présente un exemple de notre démarche et servira de base à notre choix du degré optimal, qui sera expliqué dans la section suivante.

3.2 Sélection du degré optimal des polynômes

Nous avons étudié l'évolution de l'AIC en fonction du degré du polynôme pour chacun des quatre sous-groupes : garçons et filles du Gabon, garçons et filles de Palau. L'AIC a été choisi comme critère principal afin de concilier qualité d'ajustement et complexité du modèle.
Le graphe ci-dessous illustre ces évolutions.

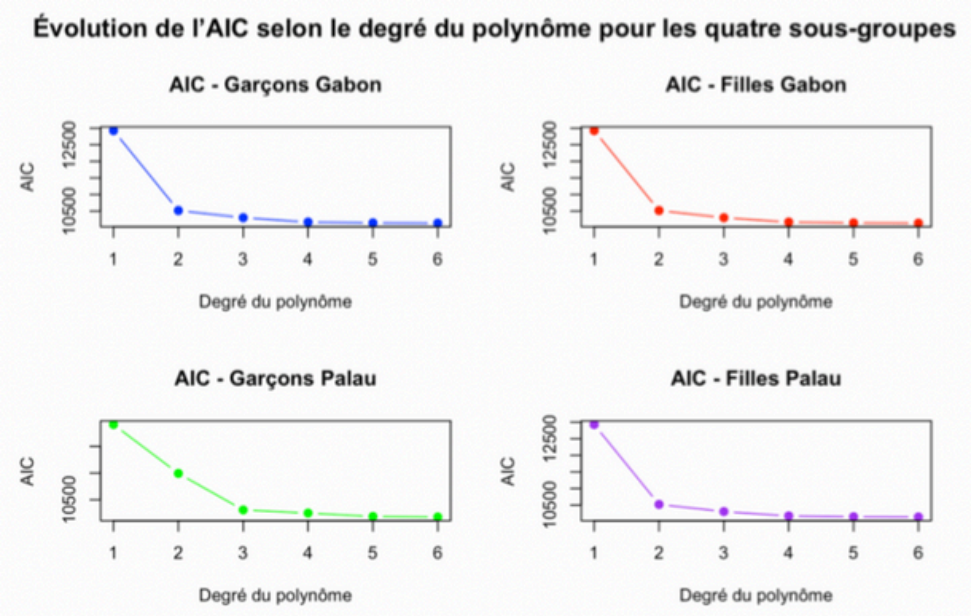

Les courbes montrent une forte baisse de l'AIC entre le degré 1 et le degré 2, ce qui indique un net progrès dès l'ajout d'un nouveau terme. L'AIC continue ensuite de baisser lorsque le degré augmente, mais les gains deviennent de plus en plus faibles à partir du degré 3. À partir du degré 4, l'AIC se stabilise dans tous les sous-groupes et les améliorations obtenues avec des degrés supérieurs sont minimes.

Nous avons retenu un polynôme de degré 4 pour chacun des sous-groupes. Ce choix nous a permis de modéliser avec précision la dynamique de croissance tout en limitant la complexité du modèle. L'observation des courbes ajustées (section 3.3) montre que ce choix suit bien la tendance des données tout en évitant le surajustement que pourraient entraîner des degrés plus élevés

3.3 Interpretation des courbes ajustées

a) Garçons - Gabon

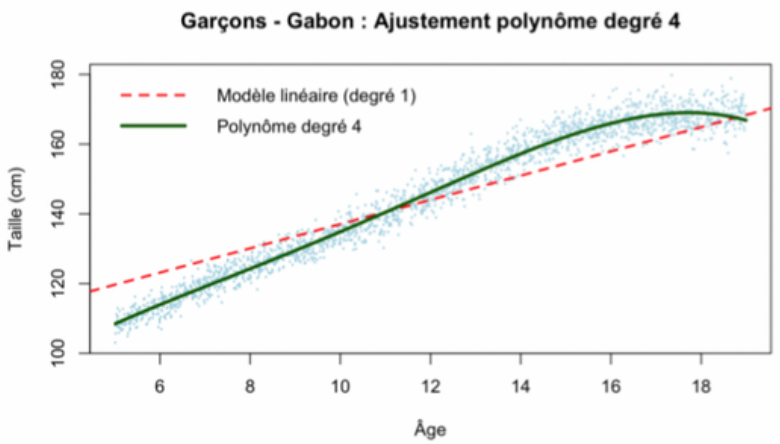

La courbe ajustée par un polynôme de degré 4 suit bien la dynamique de croissance des garçons du Gabon. Elle met en évidence une progression régulière de la taille avec l'âge, avec une accélération notable entre 10 et 15 ans, correspondant à la période de croissance rapide. On observe ensuite un ralentissement de la croissance vers 17-18 ans, lorsque la taille se stabilise.

Le polynôme de degré 4 suit correctement le nuage de points sur l'ensemble de la plage d'âges, sans surajustement. La courbe est cohérente avec la réalité biologique attendue. Elle offre un ajustement nettement plus précis que le modèle linéaire, représenté par la droite rouge. Cette droite ne prend pas en compte les différentes phases de la croissance pour refléter la relation réelle entre l'âge et la taille.
Cet ajustement confirme que le choix du degré 4 permet de bien représenter la croissance des garçons du Gabon.

b) Filles - Gabon

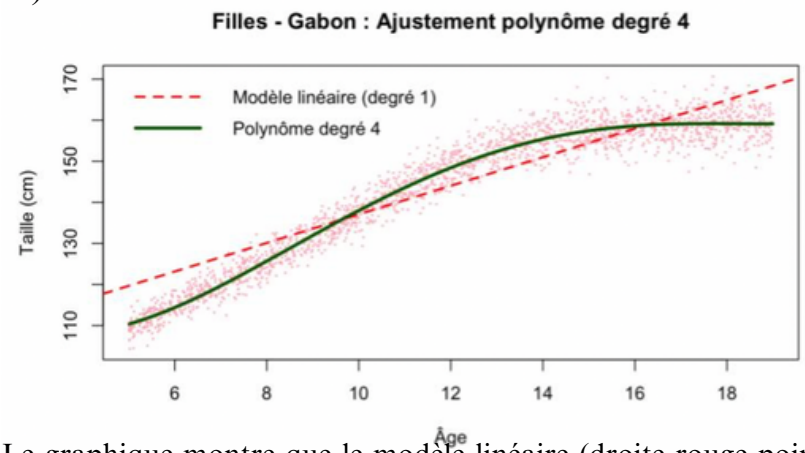

Dans cette étude, nous avons comparé deux modèles : un modèle linéaire simple (degré 1) et un modèle polynômial de degré 4, choisi selon le critère AIC (partie 3.2).

Le graphique montre que le modèle linéaire (droite rouge pointillée) traduit une croissance constante tout au long de l'âge. Bien qu'il soit statistiquement significatif (R^2 = 84,27 %), ce modèle ne prend pas en compte la réalité biologique : il ne reflète pas la phase de croissance rapide autour de 10-13 ans ni le ralentissement vers 16-17 ans. Les résidus sont relativement élevés, allant de -20,39 cm à +15,46 cm, ce qui montre des écarts importants entre les tailles observées et prédites, en particulier aux âges extrêmes.

En comparaison, le modèle polynômial de degré 4 (courbe verte) suit bien la tendance générale des données. Il met en évidence une accélération de la croissance à l'adolescence, suivie d'une stabilisation progressive, en accord avec la croissance attendue des filles. Les résidus sont mieux maîtrisés, compris entre environ -12 cm et +9,6 cm, ce qui confirme un ajustement plus précis et adapté à la dynamique réelle de la croissance.

c) Garçons - Palau

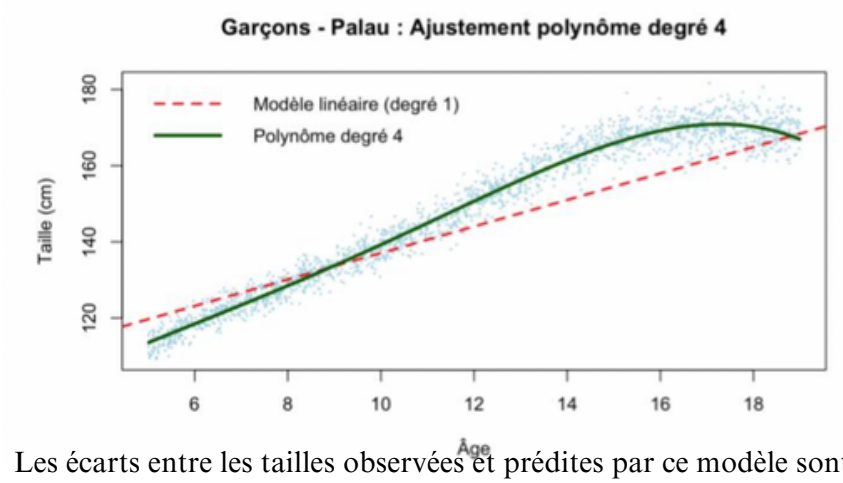

Le graphique montre que le modèle linéaire reste trop simpliste pour bien représenter les données des garçons de Palau. Bien que ce modèle soit significatif (R^2 = 93,93 %), il ne permet pas de suivre correctement la dispersion du nuage de points, notamment aux âges plus élevés
où la croissance ralentit.

Les écarts entre les tailles observées et prédites par ce modèle sont marqués, avec des résidus allant de -18,06 cm à +16,30 cm.
En comparaison, le polynôme de degré 4 (courbe verte) s'adapte bien à la forme générale des données, avec une ligne plus proche des points sur l'ensemble de la tranche d'âge. Les résidus sont réduits (entre -12,13 cm et +12,24 cm), ce qui traduit une amélioration notable de l'ajustement. Le graphique illustre un ajustement plus précis que pour les garçons du Gabon : les points sont ici globalement plus resserrés autour de la courbe, notamment en fin de croissance.

d) Filles - Palau

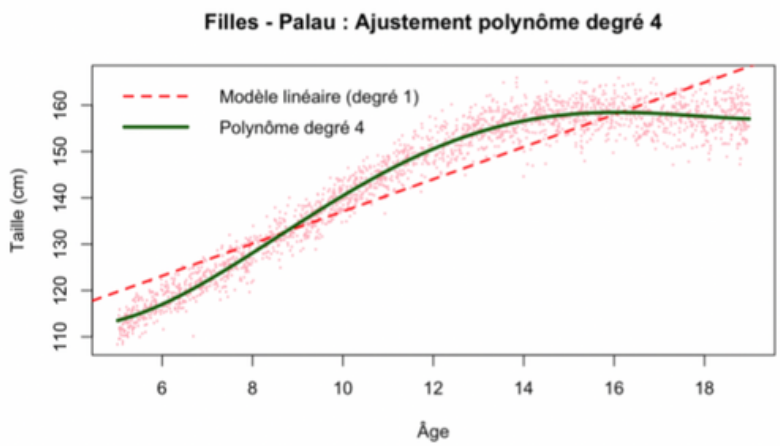

Nous avons vu tout au long de cette partie que le modèle polynômial de degré 4 offrait un ajustement bien plus précis que le modèle linéaire simple pour décrire la relation entre âge et taille.

Le graphique des filles de Palau illustre cela. Le modèle linéaire (droite rouge pointillée), bien que significatif (R^2 = 84,27 %), reste trop limité pour représenter correctement les données. Les écarts entre les tailles observées et prédites sont importants, avec des résidus compris entre -20,39 cm et +15,46 cm.

À l'inverse, le polynôme de degré 4 (courbe verte) suit de manière plus fidèle la tendance des points, avec des résidus nettement réduits (entre -12,00 cm et +9,60 cm), ce qui traduit une meilleure adéquation aux données. Le nuage de points est globalement bien accompagné par la courbe, même si la dispersion reste légèrement plus marquée en fin de croissance par rapport aux garçons de Palau, où l'ajustement semblait encore plus resserré autour de la courbe. Enfin, par rapport aux groupes du Gabon, l'ajustement polynômial reste tout aussi performant.

4. Courbes de croissance par tranche d'âge

4.1 Méthode de construction des indicateurs de croissance

Dans cette partie, nous avons choisi de représenter la croissance en fonction de l'âge à partir des données brutes, sans recours à un ajustement polynômial, afin de restituer fidèlement la tendance observée dans l'échantillon. Pour cela, nous avons regroupé l'ensemble des observations par tranches d'âge régulières de 0,5 an. Ce découpage permet d'obtenir un nombre d'observations suffisant dans chaque tranche pour calculer des indicateurs robustes, tout en conservant une bonne précision sur l'évolution de la croissance.

Pour chaque tranche d'âge, nous avons calculé :

- La **médiane** de la taille, qui traduit la tendance centrale,
- Le **premier quartile (Q1)** et le **troisième quartile (Q3)**, qui permettent de visualiser la dispersion des tailles et de cerner la moitié centrale de la population.

L'objectif de ces courbes est de mettre en évidence la trajectoire de croissance typique et la variabilité des tailles selon l'âge. Les médianes illustrent la tendance générale, tandis que les quartiles fournissent un repère sur la dispersion des tailles à chaque âge, et donc sur les différences interindividuelles dans le développement statural.
Les courbes ont été tracées séparément pour chaque sous-groupe (Garçons – Gabon, Filles – Gabon, Garçons – Palau, Filles – Palau), afin de visualiser les spécificités de chaque population étudiée.

4.2 Analyse des graphiques de croissance

a) Garçons - Gabon

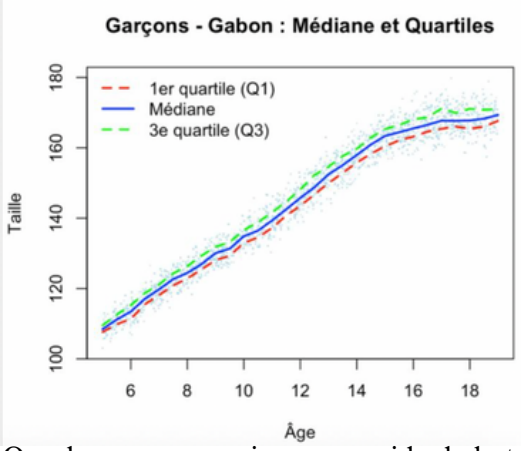

Le graphique montre la relation entre l'âge et la taille chez les garçons au Gabon. Chaque point noir représente une observation individuelle de taille pour un âge donné. La courbe bleue correspond à la médiane des tailles par tranche d'âge, tandis que les courbes vertes pointillées représentent le premier (Q1) et le troisième quartile (Q3), c'est-à-dire les limites inférieure et supérieure entre lesquelles se situe la moitié centrale des individus.

On observe une croissance rapide de la taille entre 5 et 14 ans, comme en témoigne la pente marquée de la médiane. Cette croissance ralentit ensuite à partir de 15 ans, ce qui reflète vraisemblablement la fin de la phase pubertaire. La distance croissante entre les courbes de quartiles à partir d'environ 10 ans indique une variabilité plus importante des tailles à l'adolescence. Cela peut s'expliquer par des différences dans le rythme de développement pubertaire entre les individus. La position équilibrée des quartiles autour de la médiane suggère que la répartition des tailles est globalement symétrique à chaque âge. Ce graphique met en évidence une trajectoire de croissance cohérente avec le développement biologique attendu, tout en soulignant les différences individuelles plus marquées à l'adolescence.

b) Filles - Gabon

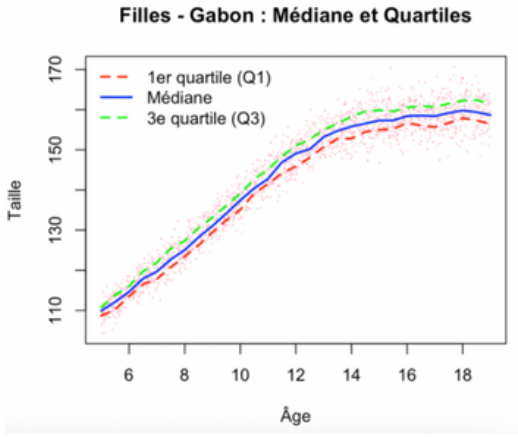

Ce graphique représente l'évolution de la taille en fonction de l'âge chez les filles au Gabon. Ces trois courbes décrivent la tendance centrale ainsi que la dispersion des tailles pour chaque âge. On observe une croissance rapide entre 5 et 12 ans, avec une médiane qui augmente de manière régulière, traduisant une croissance corporelle soutenue. À partir d'environ 13 ans, la courbe de la médiane se stabilise progressivement, signe que la croissance ralentit puis s'arrête vers 15–16 ans.

Cette stabilisation plus précoce que chez les garçons est cohérente avec la puberté généralement plus avancée chez les filles. Les courbes de quartiles montrent une dispersion modérée des tailles, légèrement plus marquée pendant la période pubertaire, ce qui témoigne des différences de rythme de croissance entre les individus. La forme de la médiane et l'écart entre les quartiles suggèrent une croissance harmonieuse, avec des différences individuelles plus visibles à l'adolescence mais moins prononcées que chez les garçons.

c) Garçons – Palau

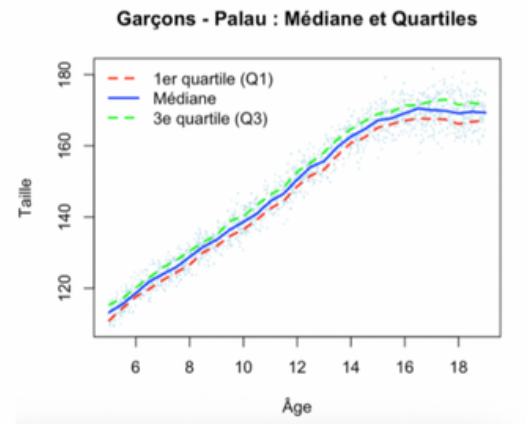

Ce graphique illustre l'évolution de la taille en fonction de l'âge chez les garçons à Palau. La courbe montre une croissance régulière de la taille de l'âge de 5 ans jusqu'à environ 14–15 ans, période durant laquelle la médiane augmente de façon continue. À partir de cet âge, la croissance ralentit nettement, et la courbe tend vers un plateau aux alentours de 170 cm, traduisant la fin de la croissance pubertaire.

L'écart entre les quartiles reste relativement constant, avec une légère augmentation à l'adolescence, ce qui traduit des différences plus marquées entre les individus dans leur rythme de croissance pendant cette période. Globalement, le profil de croissance est cohérent avec un développement typique chez les garçons, avec une croissance soutenue jusqu'à la mi-adolescence suivie d'une stabilisation. Le niveau médian atteint semble légèrement supérieur à celui observé chez les garçons du Gabon, suggérant d'éventuelles différences liées au contexte génétique, nutritionnel ou socio-économique.

d) Filles - Palau

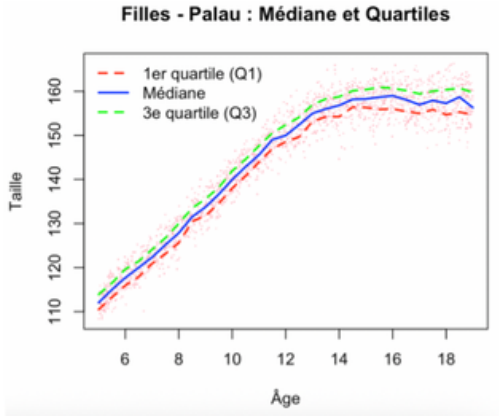

Ce graphique représente l'évolution de la taille en fonction de l'âge chez les filles vivant à Palau. On observe une croissance régulière de la taille entre 5 et 11 ans, période durant laquelle la médiane augmente de manière constante, traduisant une croissance stable et continue durant l'enfance. Entre 11 et 13 ans, la pente de la courbe médiane s'accentue légèrement, signe de l'accélération de la croissance typique de la puberté.

À partir de 14 ans, la courbe médiane commence à s'aplatir, ce qui reflète un ralentissement de la croissance. Vers 16–17 ans, la taille médiane semble se stabiliser autour de 160 cm, indiquant la fin de la croissance staturale pour la majorité des filles. L'écart entre les quartiles (zone entre les courbes vertes) s'élargit légèrement autour de la période pubertaire, ce qui témoigne d'une plus grande variabilité interindividuelle dans la vitesse et le moment de la croissance. Cela est cohérent avec le fait que la puberté peut survenir à des âges légèrement différents selon les individus.

Dans l'ensemble, le profil de croissance observé ici est cohérent avec les schémas typiques de développement chez les filles, avec une croissance plus précoce que chez les garçons et une stabilisation autour de 16–17 ans. Par comparaison avec d'autres pays, le niveau de taille médiane atteint à la fin de l'adolescence semble relativement élevé, ce qui pourrait refléter un bon état de santé général, incluant nutrition et environnement favorable.

5. Conclusion
5.1 Bilan général

Cette étude avait pour objectif de comparer les trajectoires de croissance en taille d'enfants et d'adolescents âgés de 5 à 19 ans entre deux pays, le Gabon et Palau, en distinguant filles et garçons. L'analyse descriptive a montré des distributions d'âge équilibrées entre les sous-groupes, avec des moyennes proches de 12 ans dans l'ensemble des populations. Toutefois, des différences notables ont été observées au niveau des tailles : les garçons de Palau présentent des tailles moyennes et médianes plus élevées que les garçons du Gabon, avec un niveau final atteignant environ 170 cm contre 165 cm.
Chez les filles, les tailles finales sont plus proches entre les deux pays, autour de 160 cm, bien que les filles de Palau affichent un léger avantage. Les courbes par tranches d'âge ont mis en évidence une croissance rapide durant l'enfance, suivie d'une accélération pubertaire, puis d'une stabilisation : ce schéma est similaire dans les deux pays, mais la puberté semble légèrement plus précoce et la croissance plus rapide à Palau.

Les comparaisons entre filles et garçons confirment des profils biologiques attendus. Dans les deux pays, les filles connaissent un ralentissement et une stabilisation de la croissance plus précoces que les garçons. La variabilité des tailles est plus marquée chez les garçons pendant la période pubertaire, traduisant des différences de rythme de maturation plus importantes. Les ajustements polynomiaux de degré 4 ont permis de modéliser ces trajectoires de manière précise, en montrant les limites des modèles linéaires et la capacité du polynôme à représenter les phases d'accélération et de stabilisation. Les graphiques des courbes médianes et des quartiles par tranches d'âge (réalisés en partie 4), ont complété ces résultats en illustrant directement la tendance centrale et la dispersion des tailles selon l'âge, sans modèle ajusté, et en confirmant une variabilité accrue à la puberté, particulièrement chez les garçons.

Enfin, cette étude met en lumière l'influence probable de facteurs environnementaux, nutritionnels et génétiques sur les différences observées entre les pays. Le niveau de taille finale légèrement plus élevé à Palau pourrait témoigner d'un contexte global plus favorable à la croissance (alimentation, santé, conditions de vie). Les outils statistiques et graphiques mobilisés ont permis de comparer de manière rigoureuse les trajectoires de croissance et de souligner à la fois les grandes tendances communes aux deux pays et les spécificités de chaque population.

5.2 Summary

This study compared the growth trajectories of children and adolescents aged 5 to 19 years in Gabon and Palau. We analyzed data separately for boys and girls. The descriptive analysis showed similar age distributions, with an average age of around 12 years in all groups. However, height differed between countries. Boys in Palau were taller than boys in Gabon, especially at the end of adolescence. Girls in both countries had similar final heights, with a slight advantage for girls in Palau.

Polynomial models (degree 4) provided a better fit than linear models. They captured the phases of rapid growth and the stabilization at the end of puberty. The graphs based on age groups highlighted the median growth and the variability of heights at each age. Variability was greater during puberty, especially for boys.

The study showed that growth patterns were biologically consistent. It also revealed differences that may be linked to environmental, nutritional or genetic factors. Boys and girls in Palau reached slightly higher final heights, possibly reflecting more favorable living conditions.